

Prueba Técnica Data Scientist

Antiscraping Security

Objetivo

El Challenge pone a prueba tus conocimientos en:

- Procesamiento y análisis de grandes volúmenes de datos.
- Uso de estadísticas y de Machine Learning aplicados a problemas de ciberseguridad.
- Pensamiento crítico y diseño de soluciones prácticas.
- Comunicación clara de resultados.

Tu desafío

Problema 1: Detección de scrapers en una ventana de tráfico

El archivo *session_requests.csv* contiene una muestra de tráfico de un marketplace: todas las sesiones que estuvieron activas en una misma ventana de 4 horas, con sus requests individuales (~1350 sesiones, ~190 mil requests en total). No hay historial previo de estas sesiones — toda la información disponible sobre cada una está contenida en esa misma ventana.

Columna	Descripción
session_id	Identificador de sesión
request_time	Timestamp del request
path	Path solicitado
path_type	Tipo de página (search o item)
d2id	Identificador de dispositivo
ip_address	IP de origen del request
user_agent	User-Agent del request

Se solicita desarrollar un sistema de detección de anomalías que permita identificar **sesiones con comportamiento de scraping/bot**, mediante dos enfoques distintos:

A. Análisis estadístico y etiquetado:

- Realice un análisis exploratorio de los datos para identificar patrones de comportamiento dentro de cada sesión.
- Defina reglas de normalidad — comparando el comportamiento de cada sesión contra el resto de las sesiones de la ventana — y use las reglas creadas para identificar las sesiones normales y anómalas (scraping). Incorpore esa etiqueta binaria al set de datos.
- Utilizando llamadas por API a un modelo de lenguaje (GPT, Deepseek, Gemini u otro que

elija), genere reportes sobre al menos tres sesiones que considere sospechosas según el análisis realizado.

B. Modelo por Machine Learning:

- Proponga y entrene un modelo de machine learning adecuado para los datos y considerando las etiquetas generadas por el enfoque A.
- Discuta problemáticas y estrategias que utilizaría para datasets con desbalance de datos.
- Proponga y calcule métricas relevantes para evaluar el desempeño del modelo. Justifique su elección.

Problema 2: Análisis de Vulnerabilidades con Web Scraping

Los avisos de seguridad de Debian (**Debian Security Advisories**) publican información sobre vulnerabilidades que afectan a paquetes del sistema Debian. Cada aviso incluye identificador CVE, fecha, paquete afectado y una descripción del problema.

Fuente: <https://lists.debian.org/debian-security-announce/>

- Scrapee los avisos de seguridad publicados en los últimos 3 meses. Extraiga al menos los siguientes campos: CVE ID, fecha de publicación, paquete/vendor afectado y descripción.
- A partir de la descripción de cada aviso, clasifique el/los tipo(s) de vulnerabilidad (por ejemplo: denial of service, ejecución remota de código, bypass de restricciones, exposición de información, etc). Justifique el enfoque de clasificación elegido.
- Use los datos scrapeados y clasificados para crear al menos dos visualizaciones distintas en Looker Studio / Data Studio. Explique por qué eligió esas visualizaciones y qué insights de seguridad se pueden obtener de ellas. Justifique las decisiones tomadas sobre el manejo de datos.

Entregables

Repo de GitHub:

- Código comentado y estructurado. Link de tablero en Looker Studio.
- Tu entendimiento del problema y las decisiones tomadas. Explicación de la metodología y posibles mejoras a futuro.

Buena suerte!